第3章　最佳逼近和最小二乘法

3.1　问题的提出

3.2　内积空间中的最佳逼近

3.3　函数的最佳平方逼近

3.4　勒让德多项式和切比雪夫多项式

3.5　曲线(数据)拟合的最小二乘法

3.6　$C[a,b]$中最佳一致逼近

3.5 曲线拟合的最小二乘法

在工程计算和统计分析中，常常遇到大量带有误差的实验数据，需要将这些数据拟合成一条函数曲线. 从而总结、验证变量之间满足的函数关系，称这种问题为曲线拟合. 它要求构造一个不必严格满足所有离散数据的近似函数（曲线），但使逼近的总体误差达到最小. 根据最佳平方逼近准则(2-范数度量误差)进行的曲线拟合方法就称为最小二乘法.

例1 **已知热敏电阻数据：**

温度 t(^{0}C)	20.5	32.7	51.0	73.0	95.7
电阻 R(Ω)	765	826	873	942	1032

求60^{0}C时的电阻R。

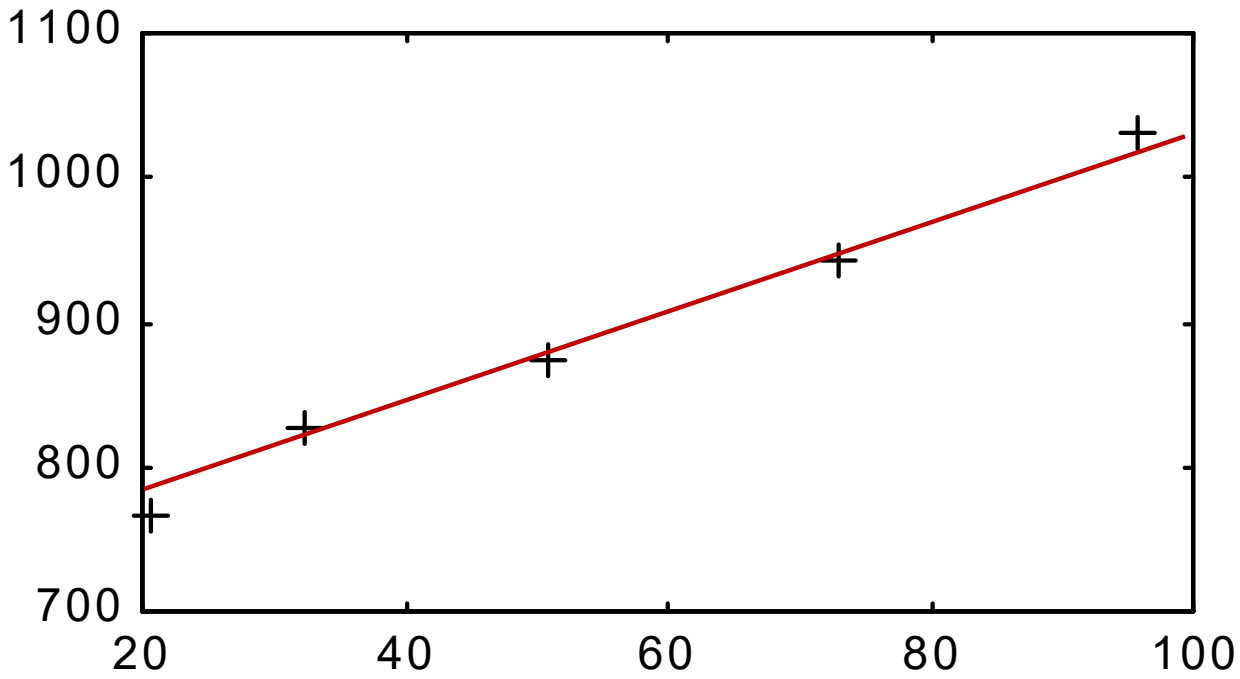

根据数据描绘散点图，数据点近似分布在一条直线上，故设拟合曲线为 $S= a+bt$，a, b为待定系数

求出待定常数a和b，使得计算值S_i与实测值R_i之间的整体绝对误差最小.

比如　误差 $E_1=\sum_{i=1}^{5}\left|(a+bt_i)-R_i\right|$

误差 $E_2=\sqrt{\sum_{i=1}^{5}[(a+bt_i)-R_i]^2}$　　最小

用E_2度量方法求出拟合曲线 $S=\boldsymbol{a}+b\,\boldsymbol{t}$ 称为一次最小二乘拟合或一次最佳平方逼近.

例2 一种药物快速静脉注射下的血药浓度数据(t =0注射300mg)

t (h)	0.25	0.5	1	1.5	2	3	4	6	8
c (μg/ml)	19.21	18.15	15.36	14.10	12.89	9.32	7.45	5.24	3.01

求血药浓度随时间的变化规律 $c(t)$.

作半对数坐标系(semilogy)下的图形

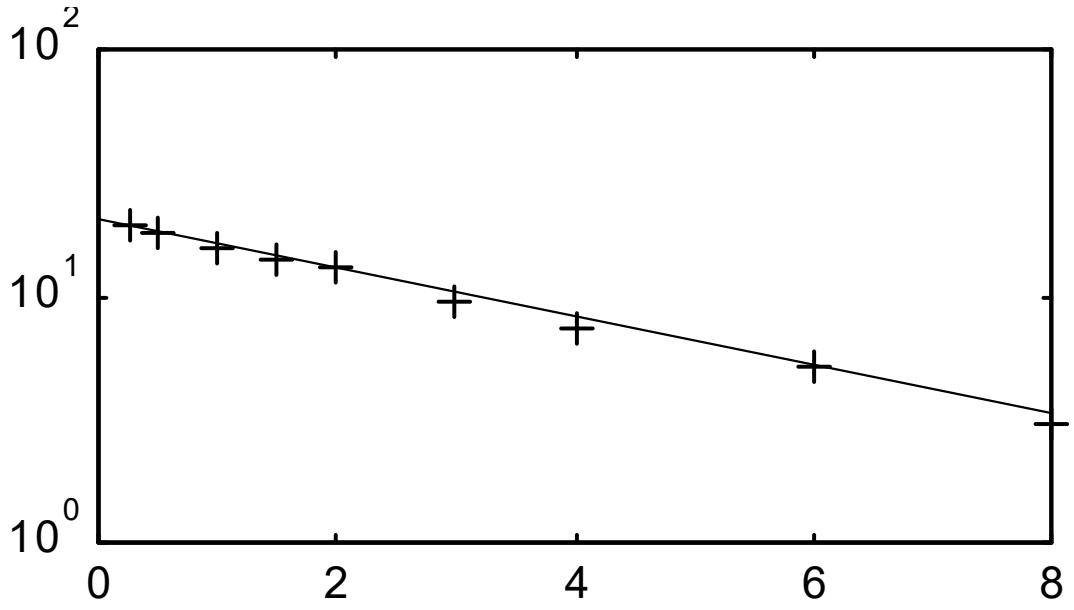

根据数据描绘散点图，设拟合曲线为

$$c(t) = c_0 e^{-kt}$$

(c_0, k为待定系数)

$$\Leftrightarrow s(t) = \ln c(t) = \ln c_0 - kt$$

即 $s(t) = a + bt$

问题的描述：已知离散数据表$(x_i, f(x_i))_{i=1\sim m}$，选取逼近表格函数$f(x)$的函数类$\phi$，求拟合函数$S^*(x)\in\phi$，使得

$$\left\|\left\{f(x_i)-S^*(x_i)\right\}_{i=1\sim m}\right\| = \min_{S(x)\in\phi}\left\|\left\{f(x_i)-S(x_i)\right\}_{i=1\sim m}\right\|$$

由于 $\delta=\{\delta_i\}\triangleq\{f(x_i)-S(x_i)\}\in R^m$,

$$\delta^*=\left\{\delta_i^*\right\}\triangleq\left\{f(x_i)-S^*(x_i)\right\}\in R^m,$$

问题即是在$\boldsymbol{m}$维向量空间R^m中的最佳逼近问题.

取2-范数时，该方法称为最小二乘法(最佳平方逼近)；

取∞-范数时，该方法称为最佳一致逼近法.

离散数据的最小二乘拟合

定义函数的离散加权内积

$$(f,\ g)=\sum_{i=1}^{m}\omega_i f(x_i)g(x_i)$$

其中ω_i为$f(x)$在点x_i处的权，$\omega_i\geq 0$，$i=1,2,\cdots,m.$

内积诱导的2-范数 $\|f\|_2=\sqrt{\sum_{i=1}^{m}\omega_i f^2(x_i)}$

注：ω_i可以表示在$(x_i,f(x_i))$处重复观测的次数.

定义 设$\{\varphi_1(x),\varphi_2(x),\cdots,\varphi_n(x)\}$是$C[a,b]$中的$n$个线性无关的函数，子空间$M=\mathrm{span}\{\varphi_1,\varphi_2,\cdots,\varphi_n\}$， $S(x)=\sum_{i=1}^{n}\alpha_i\varphi_i(x)\in M$.

已知$f(x)\in C[a,b]$在m个互异点$x_i(i=1\sim m)$测试数据$(x_i,f(x_i))_{i=1\sim m}$，

求$S^*(x)=\sum_{i=1}^{n}\alpha_i^*\varphi_i(x)\in M$，

$$\text{s.t.}\quad \sqrt{\sum_{i=1}^{m}\omega_i[f(x_i)-S^*(x_i)]^2}=\min_{S(x)\in M}\sqrt{\sum_{i=1}^{m}\omega_i[f(x_i)-S(x_i)]^2}$$

即 $$\sum_{i=1}^{m}\omega_i[f(x_i)-\sum_{j=1}^{n}\alpha_j^*\varphi_j(x_i)]^2=\min_{\{\alpha_i\}\in K^m}\sum_{i=1}^{m}\omega_i[f(x_i)-\sum_{j=1}^{n}\alpha_j\varphi_j(x_i)]^2$$

称$s^*(x)$为$f(x)$在M中的加权最小二乘拟合函数，

求$s^*(x)$的方法称为最小二乘法.

求 $G(\alpha_1,\alpha_2,\cdots,\alpha_n)=\sum_{i=1}^{m}\omega_i[f(x_i)-\sum_{j=1}^{n}\alpha_j\varphi_j(x_i)]^2$ 的最小问题

多元函数求极值的必要条件

$$\frac{\partial G}{\partial \alpha_k}=2\sum_{i=1}^{m}\omega_i[f(x_i)-\sum_{j=1}^{n}\alpha_j\varphi_j(x_i)]\varphi_k(x_i)=0,k=1\sim n$$

即 $$\sum_{j=1}^{m}[\sum_{i=1}^{n}\omega_i\varphi_j(x_i)\varphi_k(x_i)]\alpha_j=\sum_{i=1}^{m}\omega_i f(x_i)\varphi_k(x_i),k=1\sim n$$

引入向量及其内积

$$\varphi_j=(\varphi_j(x_1),\varphi_j(x_2),\cdots,\varphi_j(x_n)),f=(f(x_1),f(x_2),\cdots,f(x_n))$$

$$(\varphi_j,\varphi_k)=\sum_{i=1}^{n}\omega_i\varphi_j(x_i)\varphi_k(x_i),(f,\varphi_k)=\sum_{i=1}^{m}\omega_i f(x_i)\varphi_k(x_i)$$

$$\sum_{j=1}^{m}(\varphi_j,\varphi_k)\alpha_j=(f,\varphi_k),k=1\sim n$$

由此，得到法方程（正规方程）

$$\begin{bmatrix} (\varphi_1,\varphi_1) & (\varphi_2,\varphi_1) & \cdots & (\varphi_n,\varphi_1) \\ (\varphi_1,\varphi_2) & (\varphi_2,\varphi_2) & \cdots & (\varphi_n,\varphi_2) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_1,\varphi_n) & (\varphi_2,\varphi_n) & \cdots & (\varphi_n,\varphi_n) \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} (f,\varphi_1) \\ (f,\varphi_2) \\ \vdots \\ (f,\varphi_n) \end{bmatrix}$$

求出 $(\alpha_1^*,\cdots,\alpha_j^*,\cdots,\alpha_n^*)^T \Rightarrow s^*(x) = \sum_{j=1}^{n} \alpha_j^* \varphi_j(x)$

当 $f(x) \approx s^*(x)$时，

均方误差 $\|\delta\|_2 = \sqrt{\sum_{i=1}^{m} \omega(x_i)[f(x_i) - s^*(x_i)]^2}$

$$= \sqrt{(f,\ f) - \sum_{i=1}^{n} \alpha_i^* (f,\varphi_i)}$$

若取函数类 $\Phi = P_n = \mathrm{Span}\{1, x, x^2, \cdots, x^n\}$， 则正则方程组为

$$\begin{bmatrix} \sum_{i=1}^{n}\omega_i & \sum_{i=1}^{n}\omega_i x_i & \cdots & \sum_{i=1}^{n}\omega_i x_i^{\,n} \\ \sum_{i=1}^{n}\omega_i x_i & \sum_{i=1}^{n}\omega_i x_i^{\,2} & \cdots & \sum_{i=1}^{n}\omega_i x_i^{\,n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^{n}\omega_i x_i^{\,n} & \sum_{i=1}^{n}\omega_i x_i^{\,n+1} & \cdots & \sum_{i=1}^{n}\omega_i x_i^{\,2n} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n}\omega_i y_i \\ \sum_{i=1}^{n}\omega_i x_i y_i \\ \vdots \\ \sum_{i=1}^{n}\omega_i x_i^{\,n} y_i \end{bmatrix}$$

拟合曲线为 $$s^*(x) = \sum_{j=0}^{n}\alpha_j x^j = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \cdots + \alpha_n x^n$$

例 3. 已知数据组

x_i	0.2	0.5	0.7	0.85	1
y_i	1.221	1.649	2.014	2.340	2.718

，试用最小二乘法求 $f(x)$ 的二次拟合多项式 $P_2(x)=a_0+a_1x+a_2x^2$.

解 权 $\omega_i=1$, 取 $M=\mathrm{span}\{1,x,x^2\}\triangleq\mathrm{span}\{\varphi_0,\varphi_1,\varphi_2\}$，计算

$$(\varphi_0,\varphi_0)=\sum_{i=1}^{5}1\times1=5,\qquad (\varphi_1,\varphi_0)=\sum_{i=1}^{5}x_i\times1=3.250,$$

$$(\varphi_2,\varphi_0)=\sum_{i=1}^{5}x_i^2\times1=2.503,\qquad (\varphi_1,\varphi_1)=\sum_{i=1}^{5}x_i\times x_i=2.503,$$

$$(\varphi_2,\varphi_1)=\sum_{i=1}^{5}x_i^2\times x_i=2.090,\qquad (\varphi_2,\varphi_2)=\sum_{i=1}^{5}x_i^2\times x_i^2=1.826,$$

$$(f,\varphi_0)=\sum_{i=1}^{5}y_i\times1=9.942,\qquad (f,\varphi_1)=\sum_{i=1}^{5}y_i\times x_i=7.185,$$

$$(f,\varphi_2)=\sum_{i=1}^{5}y_i\times x_i^2=5.857.$$

法方程 $\begin{bmatrix} 5 & 3.250 & 2.503 \\ 3.250 & 2.503 & 2.090 \\ 2.503 & 2.090 & 1.826 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 9.942 \\ 7.185 \\ 5.857 \end{bmatrix}.$

求得 $a_0 = 1.036,\ a_1 = 0.751,\ a_2 = 0.928.$

故 $f(x) \approx P_2(x) = 1.036 + 0.751x + 0.928x^2$

均方误差 $\|\delta\|_2 = \sqrt{\sum_{i=1}^{5} [f(x_i) - s^*(x_i)]^2} \approx 0.0086$

均匀误差 $\|\delta\|_\infty = \max_{1 \le i \le 5} \left| f(x_i) - s^*(x_i) \right| \approx 0.0055$

$$P_2(x) = 1.036 + 0.751x + 0.928x^2$$

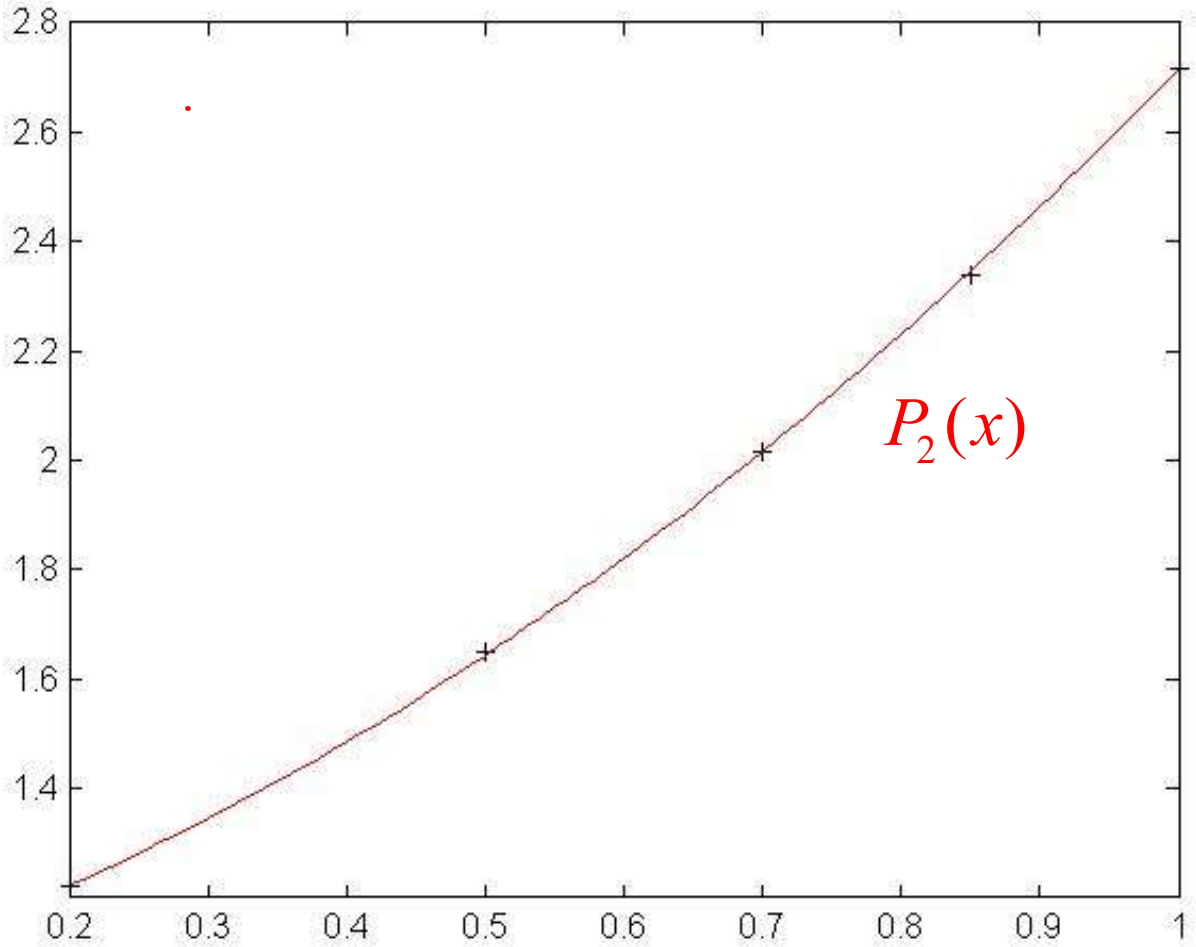

例4　已知测得铜导线在温度t_i时的电阻R_i,求电阻R与温度t的关系.

i	1	2	3	4	5	6	7
T_i	19.1	25.0	30.1	36.0	40.0	45.1	50.0
R_i	76.30	77.80	79.25	80.80	82.35	83.90	85.10

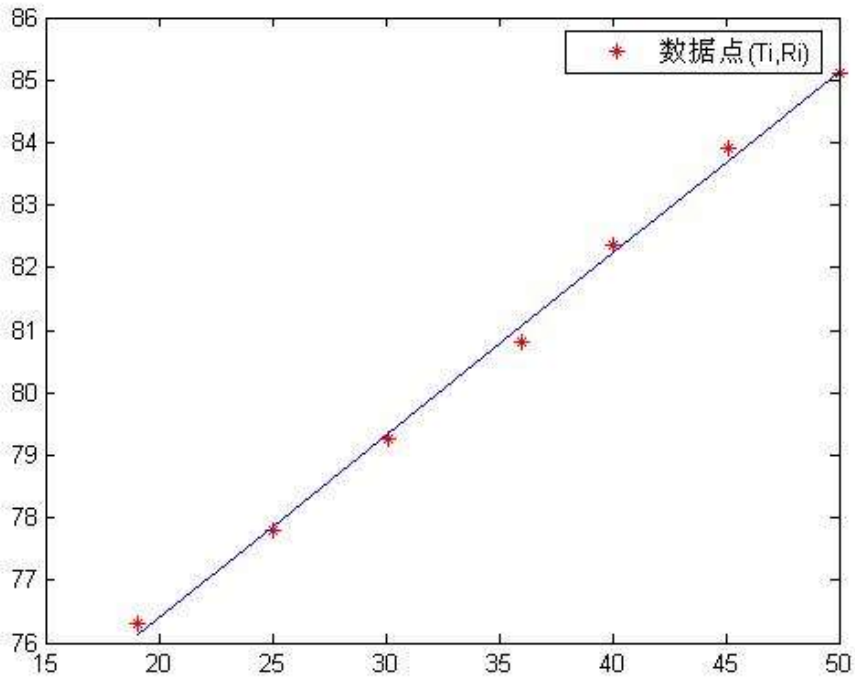

设各点的权 $\omega_i=\frac{1}{7}(i=1\sim 7)$

根据数据描绘散点图，
拟合曲线近似为

$$S=a+bt$$

i	1	2	3	4	5	6	7
t_i	19.1	25.0	30.1	36.0	40.0	45.1	50.0
R_i	76.30	77.80	79.25	80.80	82.35	83.90	85.10

解 令 $\varphi_0=1$，$\varphi_1=t$，权 $\omega_i=\frac{1}{7}(i=1,2,\cdots,7)$

$$(\varphi_0,\varphi_0)=\frac{1}{7}\sum_{i=1}^{7}1\times1=1,\ (\varphi_1,\varphi_0)=\frac{1}{7}\sum_{i=1}^{7}t_i\times1=\frac{245.3}{7},\quad (\varphi_1,\varphi_1)=\frac{1}{7}\sum_{i=1}^{7}t_i\times t_i=\frac{9325.83}{7},$$

$$(R,\varphi_0)=\frac{1}{7}\sum_{i=1}^{7}R_i=\frac{566.5}{7},\quad (R,\varphi_1)=\frac{1}{7}\sum_{i=1}^{7}R_i\times t_i=\frac{20029.445}{7}$$

法方程 $\begin{cases}7a+245.3b=566.5\\245.3a+9325.83b=20029.445\end{cases}\Rightarrow R\approx70.572+0.291t$

问： 若权 $\omega_i=1\,(i=1,2,\cdots,7)$，计算结果如何？

用最小二乘法解决实际问题的步骤：

(1) 由实验数据表，画出表格函数的粗略图形——散点图；

(2) 根据离散点的图形，选取合适的拟合函数类型 Φ，

(3) 用最佳逼近方法求出拟合函数 $\varphi(x) \in \Phi$；

(4) 通过实验结果验证拟合曲线的吻合性.

例5　已知一组实验数据(t_i, y_i)如表，用适当的函数对它们进行拟合.

t_i	1.00	1.25	1.50	1.75	2.00
y_i	5.10	5.79	6.53	7.45	8.46
$\tilde{y}_i = \ln y_i$	1.6292	1.7561	1.8764	2.0082	2.1353

解　根据数据点分布的散点图，选取拟合函数为指数函数.

设 $y \approx Ae^{bt} \Leftrightarrow \ln y \approx \ln A + bt$，记 $\tilde{y} = \ln y,\ a = \ln A$，

则只需求出拟合函数 $\tilde{y} = a + bt$.

应用最小二乘法，解相应的法方程，求得

$a = 1.1225$，$b = 0.5057 \Rightarrow A = e^a = 3.0725.$

所求数据的拟合曲线为 $y \approx 3.0725e^{0.5057t}$

拟合曲线类型的选择依据

- 专业知识和经验；
- 离散点图的分布形状及特点；
- 反复计算比较误差、修正类型；
- 现有的自动选择数学模型的程序.

法方程的病态问题

- 在最小二乘拟合中，若取基函数为 $\varphi_j(x) = x^j \, (j = 0,1,\cdots,n)$.

当 n 较大时，法方程组是病态的.

通常采用离散点的正交多项式可避免法方程出现病态.

- 实际计算中也常采用低次多项式分段拟合.

例如

若子空间$M=\mathrm{span}\{\varphi_0,\varphi_1,\cdots,\varphi_n\}$中的基$\varphi_i$ 关于数据点

(x_i,y_i) $(i=0,1,2,\cdots,m)$加权$\omega(x_i)$正交，即

$$(\varphi_j,\varphi_k)=\sum_{i=0}^{m}\omega(x_i)\varphi_j(x_i)\varphi_k(x_i)=\begin{cases}0, & j\neq k\\ A_k>0, & j=k\end{cases}$$

则法方程的解

$$a_k^*=\frac{(f,\varphi_k)}{(\varphi_k,\varphi_k)}=\frac{\sum_{i=0}^{m}\omega(x_i)f(x_i)\varphi_k(x_i)}{\sum_{i=0}^{m}\omega(x_i)\varphi_k^2(x_i)}\quad(k=0,1,\cdots,n)$$

均方误差 $\|\delta\|_2=\|f-s^*\|_2=\sqrt{\|f\|_2^2-\sum_{k=0}^{n}A_k(a_k^*)^2}$

构造离散点的正交多项式方法

根据给定的节点$x_0, x_1, \cdots, x_m$ 及权函数$\omega(x) \geq 0$，构造出带权$\omega(x)$的正交多项式 $P_0(x), \cdots, P_n(x)$ $(n \leq m)$.

$$\begin{cases} P_0(x) = 1, \\ P_1(x) = (x - \alpha_1) P_0(x), \\ P_{k+1}(x) = (x - \alpha_{k+1}) P_k(x) - \beta_k P_{k-1}(x) \quad (k = 1, 2, \cdots, n-1). \end{cases}$$

（由G.-S正交化方法得到）

$$\begin{cases} \alpha_{k+1} = \dfrac{\sum_{i=0}^{m} \omega(x_i) x_i P_k^2(x_i)}{\sum_{i=0}^{m} \omega(x_i) P_k^2(x_i)} = \dfrac{(xP_k, P_k)}{(P_k, P_k)}, \\ \beta_k = \dfrac{\sum_{i=0}^{m} \omega(x_i) P_k^2(x_i)}{\sum_{i=0}^{m} \omega(x_i) P_{k-1}^2(x_i)} = \dfrac{(P_k, P_k)}{(P_{k-1}, P_{k-1})} \end{cases} \quad (k = 0, 1, \cdots, n-1)$$

$P_0(x)$,

α_1, $P_1(x)$,

β_1, α_2, $P_2(x)$,

β_2, α_3, $P_3(x)$,

$\cdots, P_n(x)$ $(n \leq m)$.

若取$M=\mathrm{span}\{P_0,P_1,\cdots,P_n\}$, 则 $f(x)$在M中最小二乘拟合函数为

$$s^*(x)=\sum_{k=0}^{n}\alpha_k^* P_k(x)$$

其中 $$\alpha_k^*=\frac{(f,P_k)}{(P_k,P_k)}=\frac{\sum_{i=0}^{m}\omega(x_i)f(x_i)P_k(x_i)}{\sum_{i=0}^{m}\omega(x_i)P_k^2(x_i)}\ .$$

此方法求最小二乘函数不用解方程组，计算简单、稳定.

应用：最小二乘法解矛盾方程组

例5 用最小二乘法求方程组 $\begin{cases} 3x-2y=1 \\ 2x+y=2 \\ x-4y=-1 \\ 3x+2y=-3 \end{cases}$ 的近似解.

解 设 $G(x,y)=(3x-2y-1)^2+(2x+y-2)^2+(x-4y+1)^2+(3x+2y+3)^2$,

令 $\begin{cases} \dfrac{\partial G}{\partial x}=6(3x-2y-1)+4(2x+y-2)+2(x-4y+1)+6(3x+2y+3)=0 \\ \dfrac{\partial G}{\partial y}=-4(3x-2y-1)+2(2x+y-2)-8(x-4y+1)+4(3x+2y+3)=0 \end{cases}$

法方程（正规方程）为

$$\begin{cases} 23x-2y=-3 \\ -2x+25y=-2 \end{cases}$$

$$\begin{cases} x=-0.138354 \\ y=-0.070053 \end{cases}$$

例5 用最小二乘法求方程组 $\begin{cases} 3x-2y=1 \\ 2x+y=2 \\ x-4y=-1 \\ 3x+2y=-3 \end{cases}$ 的近似解.

$$A=\begin{bmatrix} 3 & -2 \\ 2 & 1 \\ 1 & -4 \\ 3 & 2 \end{bmatrix} \qquad b=\begin{bmatrix} 1 \\ 2 \\ -1 \\ -3 \end{bmatrix}$$

$$A^TA=\begin{bmatrix} 3 & 2 & 1 & 3 \\ -2 & 1 & -4 & 2 \end{bmatrix}\begin{bmatrix} 3 & -2 \\ 2 & 1 \\ 1 & -4 \\ 3 & 2 \end{bmatrix}=\begin{bmatrix} 23 & -2 \\ -2 & 25 \end{bmatrix}$$

$$A^Tb=\begin{bmatrix} 3 & 2 & 1 & 3 \\ -2 & 1 & -4 & 2 \end{bmatrix}\begin{bmatrix} 1 \\ 2 \\ -1 \\ -3 \end{bmatrix}=\begin{bmatrix} -3 \\ -2 \end{bmatrix}$$

法方程（正规方程）为

$$\begin{bmatrix} 23 & -2 \\ -2 & 25 \end{bmatrix}\begin{bmatrix} x \\ y \end{bmatrix}=\begin{bmatrix} -3 \\ -2 \end{bmatrix}$$

$$\begin{cases} x=-0.138354 \\ y=-0.070053 \end{cases}$$

3.6 $C[a,b]$中的最佳一致逼近

以2－范数作为度量误差的标准，研究了函数空间$C[a,\mathrm{b}]$中的最佳平方逼近及离散情况下的最小二乘法，得到的最佳逼近函数$S^*(x)$，误差$\|\delta\|_2$反应了$f(x)$的平均误差，但可能出现在某些点上的误差远远大于平均误差的情况。

为了解决这类问题，考虑用∞－ 范数作为度量误差的标准.（均匀误差），这就是最佳一致逼近问题。

3.6.1 最佳一致逼近多项式

定义3.6.1 设 $f(x)\in C[a,b]$，$M_n=\mathrm{span}\left\{1,x,x^2,\cdots x^n\right\}$，

若存在多项式函数$P_n^*(x)\in M_n$,使得

$$\boxed{\left\|f(x)-P_n^*(x)\right\|_\infty}=\min_{P_n(x)\in M_n}\boxed{\left\|f(x)-P_n(x)\right\|_\infty}$$

即 $$\boxed{\max_{x\in[a,b]}\left|f(x)-P_n^*(x)\right|}=\min_{P_n(x)\in M_n}\boxed{\max_{x\in[a,b]}\left|f(x)-P_n(x)\right|}$$

则称$P_n^*(x)$是$f(x)$在$[a,b]$上的最佳一致逼近多项式

或切比雪夫逼近多项式.

为了叙述和证明的方便，引入偏差的相关定义

定义 3.6.2 偏差　设 $f(x)\in C[a,b]$，$P_n(x)\in M_n$，称

$$\Delta(f,P_n)=\|f-P_n\|_\infty=\max_{a\le x\le b}|f(x)-P_n(x)|$$

为 $f(x)$ 与 $P_n(x)$ 在 $[a,b]$ 上的偏差.

$$\|f(x)-P_n^*(x)\|_\infty=\min_{P_n(x)\in M_n}\|f(x)-P_n(x)\|_\infty$$

$$\Longleftrightarrow \quad \Delta(f,P_n^*)=\min_{P_n(x)\in M_n}\Delta(f,P_n)$$

几何上，$f(x)$ 与 $P_n(x)$ 在 $[a,b]$ 上的偏差是曲线 $y=f(x)$ 与

$y=P_n(x)$ 在垂直方向上距离最远的两点之间的距离。

$$\Delta(f,P_n^*)=\min_{P_n(x)\in M_n}\Delta(f,P_n)$$

定义 3.6.3 最小偏差

给定 $f(x)\in C[a,b]$，任给 $P_n(x)\in M_n$,

显然 $\Delta(f,P_n)\geq 0$， 对所有 $P_n(x)\in M_n$,

偏差构成的集合 $\{\Delta(f,P_n):P_n\in M_n\}$ 有下界0.

称集合的下确界 $E_n=\inf_{P_n\in M_n}\{\Delta(f,P_n)\}$

为$f(x)$ 在 $[a,b]$ 上(与所有n次多项式)的最小偏差.

下确界：可理解为最大下界，
大于**En**的任何数都不是偏差集合的下界

最小偏差

$$E_n = \inf_{P_n \in M_n} \{\Delta(f, P_n)\}$$

定义3.6.4 最佳一致逼近或最小偏差逼近多项式

设 $f(x) \in C[a,b]$，若存在 $P_n^*(x) \in M_n$，满足

$$\Delta(f, P_n^*) = E_n$$

则称 $P_n^*(x)$ 为 $f(x)$ 在 $[a,b]$ 上的最佳一致逼近多项式，

或最小偏差逼近多项式.

定理 3.6.1 最佳一致逼近多项式的存在性

设 $f(x) \in C[a,b]$，则一定存在 $P_n^*(x) \in M_n$，使

$$\Delta(f, P_n^*) = \left\| f(x) - P_n^*(x) \right\|_\infty = E_n$$

参考文献：王德人，杨忠华. 数值逼近引论. 高等教育出版社，1990

偏差 $\Delta(f, P_n) = \|f - P_n\|_\infty$

定义5 设 $f(x) \in C[a,b]$, $P_n(x) \in M_n$,

若在点 $x = x_0$ 处有

$$|P_n(x_0) - f(x_0)| = \max_{a \le x \le b} |P_n(x) - f(x)| = \mu$$

则称 x_0 是 $P_n(x)$ 的偏差点.

若 $P_n(x_0) - f(x_0) = \mu$, 称 x_0为“正”偏差点.

若 $P_n(x_0) - f(x_0) = -\mu$, 称 x_0为“负”偏差点.

由于 $P_n(x) - f(x)$ 是 $[a,b]$ 上的连续函数，根据闭区间上连续函数理论，偏差点一定存在，即至少存在一点 $x_0 \in [a,b]$，使 $|P_n(x_0) - f(x_0)| = \mu$。

定理 3.6.2（Chebyshev 定理）

最佳一致逼近多项式正、负偏差点的存在性

设 $P(x)\in M_n$ 是 $f(x)\in C[a,b]$ 的最佳一致逼近多项式，

则 $P(x)$ 同时存在正、负偏差点.

证：$\because$ $P(x)$是$f(x)$ 的最佳逼近多项式

$\therefore$ $P(x)$在$[a,b]$上总有偏差点存在　故 $\mu=E_n$

（反证法）

假定只有正偏差点，没有负偏差点　则对 $\forall x\in[a,b]$ 都有

$$P(x)-f(x)>-E_n$$

由于$P(x)-f(x)$在$[a,b]$上连续，故其最小值大于$-E_n$

用 $-E_n+2h$（$h>0$）表示最小值

定理 3.6.2（Chebyshev 定理）

最佳一致逼近多项式正、负偏差点的存在性

设 $P(x)\in M_n$ 是 $f(x)\in C[a,b]$ 的最佳一致逼近多项式，

则 $P(x)$ 同时存在正、负偏差点.

证：则对 $\forall x\in[a,b]$ 都有 $-E_n+2h\le P(x)-f(x)\le E_n$

故 $$-E_n+h\le[P(x)-h]-f(x)\le E_n-h$$

即 $$\left|[P(x)-h]-f(x)\right|\le E_n-h$$

此式表明 $P(x)-h$ 与 $f(x)$ 的偏差小于 E_n

显然与 E_n 是最小偏差的定义矛盾

同理可证，只有负偏差点没有正偏差点也是不成立的.

定理 3.6.3 最佳一致逼近多项式的正、负偏差点

$P(x)\in M_n$ 是 $f(x)$ 的最佳逼近多项式的充分必要条件是

$P(x)$在 $[a,b]$ 上至少有n+2个轮流为正、负的偏差点，

切比雪夫交错点组

即有n+2个点 $a\le x_1<x_2<\cdots<x_{n+2}\le b,$ （1）

使得 $P(x_k)-f(x_k)=(-1)^k\sigma\|P(x)-f(x)\|_\infty$ ， （2）

$\sigma=\pm1,\ k=1,2,\cdots,n+2$

证： （充分性）

设多项式 $P(x)$在$[a,b]$上有n+2个点

$a\le x_1<x_2<\cdots<x_{n+2}\le b,$ 使（2）成立.

则 $|P(x_k)-f(x_k)|=\|P(x)-f(x)\|_\infty=\mu$

若$P(x)$不是 $f(x)$ 的最佳逼近多项式，则有多项式 $Q(x)\in M_n$ ，

使得

$$\|Q(x)-f(x)\|_\infty<\|P(x)-f(x)\|_\infty=\mu$$

定理 3.6.3 最佳一致逼近多项式的正、负偏差点

$P(x)\in M_n$ 是 $f(x)$ 的最佳逼近多项式的充分必要条件是

$P(x)$在 $[a,b]$ 上至少有n+2个轮流为正、负的偏差点，

证： $\|Q(x)-f(x)\|_\infty<\|P(x)-f(x)\|_\infty=\mu$

考虑多项式 $P(x)-Q(x)=[P(x)-f(x)]-[Q(x)-f(x)]$

$\because P(x_k)-Q(x_k)=[P(x_k)-f(x_k)]-[Q(x_k)-f(x_k)]$

若 $P(x_k)-f(x_k)>0$，因 $\|Q(x_k)-f(x_k)\|<\mu$ $\therefore$ 上式右端>0

若 $P(x_k)-f(x_k)=-\mu<0$, 因 $\|Q(x_k)-f(x_k)\|<\mu$ $\therefore$ 上式右端<0

故 $P(x_k)-f(x_k)$和$P(x_k)-Q(x_k)$同号，

从而$P(x)-Q(x)$在 $[a,b]$上有n+2个点轮流取正、负号.

由连续函数性质知，$P(x)-Q(x)$在 $[a,b]$ 上有n+1个零点.

另一方面，$\because P(x)-Q(x)\neq 0$ 它是一个不超过n次的多项式.

它至多有n个零点，矛盾!

定理 3.6.3 最佳一致逼近多项式的正、负偏差点

$P(x)\in M_n$ 是 $f(x)$ 的最佳逼近多项式的充分必要条件是

$P(x)$在 $[a,b]$ 上至少有n+2个轮流为正、负的偏差点，

即有n+2个点 $a\le x_1<x_2<\cdots<x_{n+2}\le b,$

使得 $$\boxed{P(x_k)-f(x_k)=(-1)^k\sigma\left\|P(x)-f(x)\right\|_\infty},$$

$$\sigma=\pm1,\ k=1,2,\cdots,n+2$$

必要性参见：徐利治等.《函数逼近的理论与方法》

说明：1：$\sigma=\pm1$ 的取法. 当 $P(x_1)-f(x_1)>0$, 则 σ 取 -1,

当 $P(x_1)-f(x_1)<0$, 则 σ 取 1.

2：如果 $P(x)$ 在 $[a,b]$ 上是 $f(x)$ 的最佳逼近多项式，那么，

在 $[a,b]$ 的一个子区间上是否还是 $f(x)$ 的最佳逼近多项式呢?

不一定！

定理3.6.3及推论：给出了最佳一致逼近多项式的特性及求法：只要找到切比雪夫交错点组，通过插值可找到最佳一致逼近多项式。

1）求出n+2个切比雪夫交错点组，则必有n+1个点使得

$$f(x)-P_n(x)=0$$

2）利用n+1个点构造插值多项式就是 $P_n(x)$

困难：对一般连续函数，切比雪夫交错点组不宜确定！要求出最佳一致逼近多项式相当困难。

简单情形：**1.连续函数的一次最佳逼近多项式**

2.高次多项式的低次最佳一致逼近

3.6.2 一次最佳一致逼近多项式

1.连续函数的一次最佳逼近多项式

设$f(x)\in C^2[a,b]$，且$f''(x)$在(a,b)内不变号

求$f(x)$的一次最佳逼近多项式$P_1(x)=a_0+a_1x$.

由定理3.6.3知，至少需要3个切比雪夫交错点 $a\le x_1<x_2<x_3\le b$,

使得 $P_1(x_k)-f(x_k)=(-1)^k\sigma\|P_1(x)-f(x)\|_\infty$

令 $R(x)=P_1(x)-f(x)$

$\because$ $f''(x)$在(a,b)内不变号， $\therefore$ 由$R''(x)=-f''(x)$知 $R'(x)$ 单调

且$R'(x)$在(a,b)内只有一个零点，记作x_2，

于是 $P_1'(x_2)-f'(x_2)=a_1-f'(x_2)=0$ 即 $f'(x_2)=a_1$

而其余偏差点必在区间的两个端点，即 $x_1=a,\ x_3=b$

$$P_1(a)-f(a)=P_1(b)-f(b)=-[P_1(x_2)-f(x_2)]$$

代入$P_1(x)$，得：
$$\begin{cases} a_0+a_1a-f(a)=a_0+a_1b-f(b) \\ a_0+a_1a-f(a)=f(x_2)-(a_0+a_1x_2) \end{cases}$$

解得：
$$a_1=\frac{f(b)-f(a)}{b-a}=f'(x_2)$$

$$a_0=\frac{1}{2}[f(a)+f(x_2)]-\frac{f(b)-f(a)}{b-a}\cdot\frac{a+x_2}{2}$$

$f(x)$的一次最佳逼近多项式$P_1(x)=a_0+a_1x$.

例1： 求$f(x)=\sqrt{1+x^2}$在$[0,1]$的一次最佳一致逼近多项式，并计算误差.

解：$\because f'(x)=\dfrac{x}{\sqrt{1+x^2}}$，$f''(x)=\dfrac{1}{1+x^2}>0$

$$\therefore a_1=\frac{f(1)-f(0)}{1-0}=\sqrt{2}-1,\quad 又\quad a_1=f'(x_2)=\frac{x_2}{\sqrt{1+x_2^2}}$$

求得 $x_2=\sqrt{\dfrac{\sqrt{2}-1}{2}}\approx 0.4551$

$$f(x_2)=\sqrt{1+x_2^2}\approx 1.0986$$

因而 $a_0=\dfrac{1+\sqrt{1+x_2^2}}{2}-a_1\dfrac{x_2}{2}\approx 0.955$

所以$f(x)=\sqrt{1+x^2}$在$[0,1]$的一次最佳一致逼近多项式

$$P_1(x)=0.955+0.414x$$

2.高次多项式的低次最佳一致逼近

定理3.6.4 最小零偏差多项式定理

在区间$[-1,1]$上最高项系数为1的一切n次多项式中，

$\omega_n(x)=\dfrac{1}{2^{n-1}}T_n(x)$与0的偏差最小，其偏差为$\dfrac{1}{2^{n-1}}$.

证: $\forall P_n(x)=\Phi_n$, $\max\limits_{|x|\le 1}|\omega_n(x)-0|=\min\limits_{P_n\in\Phi_n}\max\limits_{|x|\le 1}|P_n(x)-0|$

$$\omega_n(x)=\frac{1}{2^{n-1}}T_n(x)=x^n-P_{n-1}^*(x) \qquad P_n(x)=x^n-P_{n-1}(x)$$

点$x_k=\cos\left(\dfrac{k}{n}\pi\right)$, $k=0,1,\cdots,n$是 $\omega_n(x)$的切比雪夫交错点组.

$\therefore$ 区间$[-1,1]$上 x^n 的最佳n-1次逼近多项式为 $P_{n-1}^*(x)$

即$\omega_n(x)=\dfrac{1}{2^{n-1}}T_n(x)$是与0的偏差最小的多项式.

$$\max_{-1\le x\le 1}|\omega_n(x)-0|=\frac{1}{2^{n-1}}\max_{-1\le x\le 1}|T_n(x)|=\frac{1}{2^{n-1}}$$

高次多项式的低次最佳一致逼近

要使 $\max\limits_{|x|\le 1}\left|P(x)-P_{n-1}^{*}(x)\right|$ 最小

$$P(x)-P_{n-1}^{*}(x)=\frac{1}{2^{n-1}}T_n(x)$$

$$\therefore\ P_{n-1}^{*}(x)=P(x)-\frac{1}{2^{n-1}}T_n(x)$$

例 2: 求 $f(x)=2x^3+x^2+2x-1$ 在 $[-1,1]$ 上的次数不超过2的最佳逼近多项式.

解: 令 $f_1(x)=\frac{1}{2}f(x)$ 由定理3.6.4知

$$f_1(x)-\overline{P}_2^{*}(x)=\frac{1}{2^2}T_3(x) \quad \text{即} \quad f(x)-2\overline{P}_2^{*}(x)=\frac{1}{2}T_3(x)$$

令 $P_2^{*}(x)=2\overline{P}_2^{*}(x)$ 得 $P_2^{*}(x)=f(x)-\frac{1}{2}T_3(x)=x^2-\frac{7}{2}x-1.$

内容小结

内积空间中的最佳逼近

1. 在$C[a,b]$中 $\begin{cases} M=\mathrm{span}\{1,x,x^2,\cdots,x^n\} \\ M=\mathrm{span}\{\text{正交多项式}\} \end{cases}$ 勒让德多项式 切比雪夫多项式

最佳平方逼近

$$\|\delta\|_2^2=\|f(x)-S^*(x)\|_2^2=\min_{S(x)\in M}\int_a^b p(x)[f(x)-S(x)]^2dx$$

2. 在R^m中 $M=\mathrm{span}\{x_1,x_2,\cdots,x_n\}$

最小二乘法 $\|\delta\|_2^2=\min_{S(x)\in M}\sum_{i=1}^{n}[f(x_i)-S(x_i)]^2$

3. 在 $\mathrm{C}[a,b]$ 中，最佳一致逼近

$$\|\delta\|_\infty=\|f(x)-P_n^*(x)\|_\infty=\min_{P_n(x)\in M_n}\|f(x)-P_n(x)\|_\infty$$

作业　**P85 习题3**

1, 2, 3, 5, 7, 8, 10, 11, 12, 13